PROJETO: DATA WAREHOUSE E BI

Análise de Filmes

1. Introdução

O presente projeto tem como objetivo o desenvolvimento de um **Data Warehouse** e a aplicação de conceitos de **Business Intelligence (BI)** utilizando dados reais do dataset MovieLens.

A proposta consiste em construir um ambiente analítico capaz de armazenar, processar e analisar avaliações de filmes realizadas por usuários, permitindo identificar padrões de comportamento, preferências e tendências ao longo do tempo.

1.1 Objetivos

- Modelar um Data Warehouse utilizando modelo dimensional
- Implementar um processo de ETL (Extract, Transform, Load)
- Carregar os dados em um banco PostgreSQL
- Realizar consultas analíticas
- Desenvolver dashboards no Power BI

2. Conjunto de Dados

2.1 Fonte

Foi utilizado o dataset MovieLens, contendo:

- movies.csv
- ratings.csv
- tags.csv

2.2 Estrutura dos dados

- movies.csv

- movieId
- title
- genres

- ratings.csv

- userId
- movieId
- rating
- timestamp

- tags.csv

- userId
- movieId
- tag
- Timestamp

3. Projeto do Data Warehouse

3.1 Modelo Dimensional (Star Schema)

O modelo adotado foi o **Star Schema**, composto por:

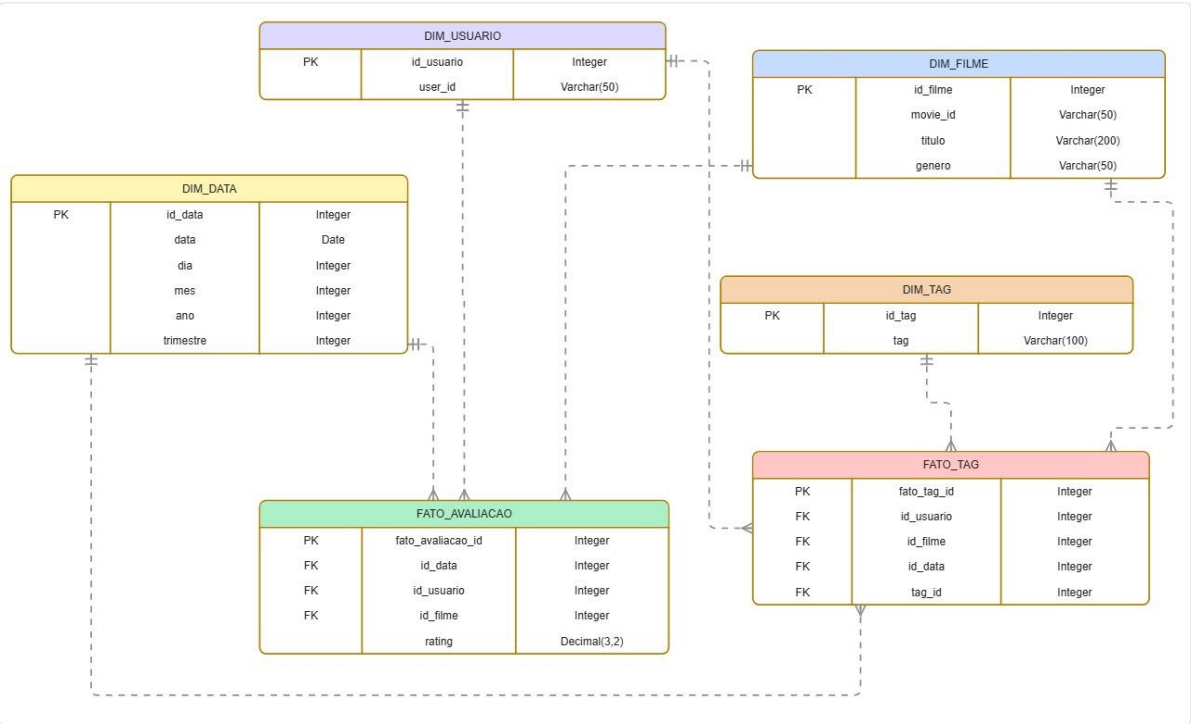

3.2 Decisões de Modelagem

- Uso de chaves substitutas (IDs)
- Separação entre fatos e dimensões
- Explosão de gêneros (um filme pode ter vários)

- Inclusão de tags para enriquecer análise
- Modelo otimizado para consultas analíticas (OLAP)

4. Pipeline ETL

4.1 Extract

Os dados foram extraídos de arquivos CSV utilizando a linguagem Python com a biblioteca pandas.

4.2 Transform

As transformações realizadas incluem:

- Tratamento de valores nulos
- Conversão de timestamps para data
- Extração de dia, mês, ano e trimestre
- Separação de múltiplos gêneros
- Padronização de dados

4.3 Load

Os dados foram carregados no banco PostgreSQL:

- Inserção nas dimensões
- Criação de mapas de relacionamento
- Inserção na tabela fato

4.4 Ferramentas

- Python (pandas, psycopg2)
- PostgreSQL
- Power BI

5. Análise dos Dados

5.1 Perguntas de Negócio

Foram elaboradas perguntas como:

- Quais são os filmes mais populares?
- Quais filmes possuem melhor avaliação?
- Quais gêneros são mais assistidos?
- Como evoluem as avaliações ao longo do tempo?
- Quais usuários são mais ativos?
- Qual a distribuição das notas?
- Existe relação entre popularidade e qualidade?
- Quais filmes são populares, porém mal avaliados?
- Quais são as tags mais utilizadas?
- Qual a média de avaliação por tag?

5.2 Ferramenta de Análise

Foi utilizado o Power BI para criação de dashboards interativos conectados ao Data Warehouse.

6. Consultas Analíticas

Consultas realizadas:

1. Quais são os filmes mais bem avaliados?

Identifica conteúdos com maior qualidade percebida pelos usuários.

```
SELECT f.titulo, AVG(a.rating) AS media
FROM fato_avaliacao a
JOIN dim_filme f ON a.id_filme = f.id_filme
GROUP BY f.titulo
HAVING COUNT(*) > 50
ORDER BY media DESC
LIMIT 10;
```

	titulo text	media double precision
1	Shawshank Redemption, The (1994)	4.429022082018927
2	Godfather, The (1972)	4.2890625
3	Fight Club (1999)	4.272935779816514
4	Cool Hand Luke (1967)	4.271929824561403
5	Dr. Strangelove or: How I Learned to Stop Worrying and Love the Bomb (19...	4.268041237113402
6	Rear Window (1954)	4.261904761904762
7	Godfather: Part II, The (1974)	4.25968992248062
8	Departed, The (2006)	4.252336448598131
9	Goodfellas (1990)	4.25
10	Casablanca (1942)	4.24

2. Quais são os filmes com maior número de avaliações?

Indica os filmes mais populares e com maior engajamento.

```
SELECT f.titulo, COUNT(*) AS total_avaliacoes
FROM fato_avaliacao a
JOIN dim_filme f ON a.id_filme = f.id_filme
GROUP BY f.titulo
ORDER BY total_avaliacoes DESC
LIMIT 10;
```

	titulo text	total_avaliacoes bigint
1	Forrest Gump (1994)	329
2	Shawshank Redemption, The (1994)	317
3	Pulp Fiction (1994)	307
4	Silence of the Lambs, The (1991)	279
5	Matrix, The (1999)	278
6	Star Wars: Episode IV - A New Hope (1977)	251
7	Jurassic Park (1993)	238
8	Braveheart (1995)	237
9	Terminator 2: Judgment Day (1991)	224
10	Schindler's List (1993)	220

3. Quais gêneros de filmes são mais populares?

Ajuda a entender preferências do público.

```
SELECT genero, COUNT(*) AS total
FROM dim_filme f
JOIN fato_avaliacao a ON f.id_filme = a.id_filme
GROUP BY genero
ORDER BY total DESC;
```

	genero text	total bigint
1	Thriller	24730
2	Drama	14787
3	Romance	14390
4	Comedy	10835
5	Sci-Fi	9375
6	Fantasy	5260
7	War	4635
8	IMAX	4145
9	Crime	2393
10	Musical	2375

4. Qual é a média de avaliação por gênero?

Permite identificar quais tipos de filmes têm melhor aceitação.

```
SELECT genero, AVG(a.rating) AS media
FROM dim_filme f
JOIN fato_avaliacao a ON f.id_filme = a.id_filme
GROUP BY genero
ORDER BY media DESC;
```

	genero text	media double precision
1	War	3.823732470334412
2	Documentary	3.8187560738581148
3	Film-Noir	3.7465277777777777
4	Animation	3.675531914893617
5	Adventure	3.673344947735192
6	Drama	3.6680530195441943
7	Mystery	3.62001399580126
8	IMAX	3.618335343787696
9	Western	3.5896029258098223
10	Musical	3.5505263157894738

5. Como evoluiu o número de avaliações ao longo do tempo?

Mostra tendências de crescimento ou queda no uso da plataforma.

```
SELECT d.ano, COUNT(*) AS total
FROM fato_avaliacao a
JOIN dim_data d ON a.id_data = d.id_data
GROUP BY d.ano
ORDER BY d.ano;
```

	ano integer	total bigint
1	1996	6040
2	1997	1916
3	1998	507
4	1999	2439
5	2000	10061
6	2001	3922
7	2002	3478
8	2003	4014
9	2004	3279
10	2005	5813

6. Em quais anos houve maior volume de avaliações?

Ajuda a identificar períodos de maior atividade dos usuários.

```
SELECT d.ano, COUNT(*) AS total
FROM fato_avaliacao a
JOIN dim_data d ON a.id_data = d.id_data
GROUP BY d.ano
ORDER BY total DESC;
```

	ano integer	total bigint
1	2000	10061
2	2017	8198
3	2007	7114
4	2016	6703
5	2015	6616
6	2018	6418
7	1996	6040
8	2005	5813
9	2012	4656
10	2008	4351

7. Existe relação entre popularidade (quantidade de avaliações) e nota média?

Permite analisar se filmes populares também são bem avaliados.

```
SELECT f.titulo,
       COUNT(*) AS total_avaliacoes,
       AVG(a.rating) AS media
FROM fato_avaliacao a
JOIN dim_filme f ON a.id_filme = f.id_filme
GROUP BY f.titulo
HAVING COUNT(*) > 50
```

```
ORDER BY total_avaliacoes DESC;
```

	titulo text	total_avaliacoes bigint	media double precision
1	Forrest Gump (1994)	329	4.164133738601824
2	Shawshank Redemption, The (1994)	317	4.429022082018927
3	Pulp Fiction (1994)	307	4.197068403908795
4	Silence of the Lambs, The (1991)	279	4.161290322580645
5	Matrix, The (1999)	278	4.192446043165468
6	Star Wars: Episode IV - A New Hope (1977)	251	4.231075697211155
7	Jurassic Park (1993)	238	3.75
8	Braveheart (1995)	237	4.031645569620253
9	Terminator 2: Judgment Day (1991)	224	3.970982142857143
10	Schindler's List (1993)	220	4.225

8. Quais são os filmes com muitas avaliações, mas baixa nota média?

Ajuda a identificar conteúdos populares, mas mal avaliados.

```
SELECT f.titulo,
       COUNT(*) AS total_avaliacoes,
       AVG(a.rating) AS media
FROM fato_avaliacao a
JOIN dim_filme f ON a.id_filme = f.id_filme
GROUP BY f.titulo
HAVING COUNT(*) > 50 AND AVG(a.rating) < 3
ORDER BY total_avaliacoes DESC;
```

	titulo text	total_avaliacoes bigint	media double precision
1	Batman Forever (1995)	137	2.9160583941605838
2	Home Alone (1990)	116	2.9956896551724137
3	Waterworld (1995)	115	2.9130434782608696
4	Ace Ventura: When Nature Calls (1995)	88	2.727272727272727
5	Nutty Professor, The (1996)	82	2.731707317073171
6	Mission: Impossible II (2000)	77	2.7142857142857144
7	Charlie's Angels (2000)	72	2.7222222222222223
8	Honey, I Shrunk the Kids (1989)	68	2.7573529411764706
9	Lost World: Jurassic Park, The (1997)	67	2.753731343283582
10	Austin Powers in Goldmember (2002)	65	2.8461538461538463

9. Quais usuários são mais ativos na plataforma?

Identifica usuários com maior número de avaliações.

```
SELECT u.user_id, COUNT(*) AS total_avaliacoes
FROM fato_avaliacao a
JOIN dim_usuario u ON a.id_usuario = u.id_usuario
GROUP BY u.user_id
ORDER BY total_avaliacoes DESC
LIMIT 10;
```

	user_id integer	total_avaliacoes bigint
1	414	2698
2	599	2478
3	474	2108
4	448	1864
5	274	1346
6	610	1302
7	68	1260
8	380	1218
9	606	1115
10	288	1055

10. Qual a distribuição das notas dadas pelos usuários?

Permite entender o comportamento geral de avaliação (ex: maioria dá nota alta ou baixa).

```
SELECT rating, COUNT(*) AS total
FROM fato_avaliacao
GROUP BY rating
ORDER BY rating;
```

	rating double precision	total bigint
1	0.5	1370
2	1	2811
3	1.5	1791
4	2	7551
5	2.5	5550
6	3	20047
7	3.5	13136
8	4	26818
9	4.5	8551
10	5	13211

7. Conclusão

O projeto permitiu aplicar conceitos fundamentais de Business Intelligence, incluindo modelagem dimensional, ETL e análise de dados.

A utilização do dataset MovieLens possibilitou explorar dados reais e gerar insights relevantes sobre comportamento de usuários e características de filmes.

A inclusão de dados de tags agregou valor analítico ao projeto, permitindo uma análise mais aprofundada e diferenciada.