MovieLens

Projeto de Business Intelligence

Maria Vitória Kuhn

MovieLens

O presente projeto tem como objetivo o desenvolvimento de um Data Warehouse e a aplicação de conceitos de Business Intelligence (BI) utilizando dados reais do dataset MovieLens.

A proposta consiste em construir um ambiente analítico capaz de armazenar, processar e analisar avaliações de filmes realizadas por usuários, permitindo identificar padrões de comportamento, preferências e tendências ao longo do tempo.

Arquivos

movies.csv

ratings.csv

tags.csv

Modelagem de dados

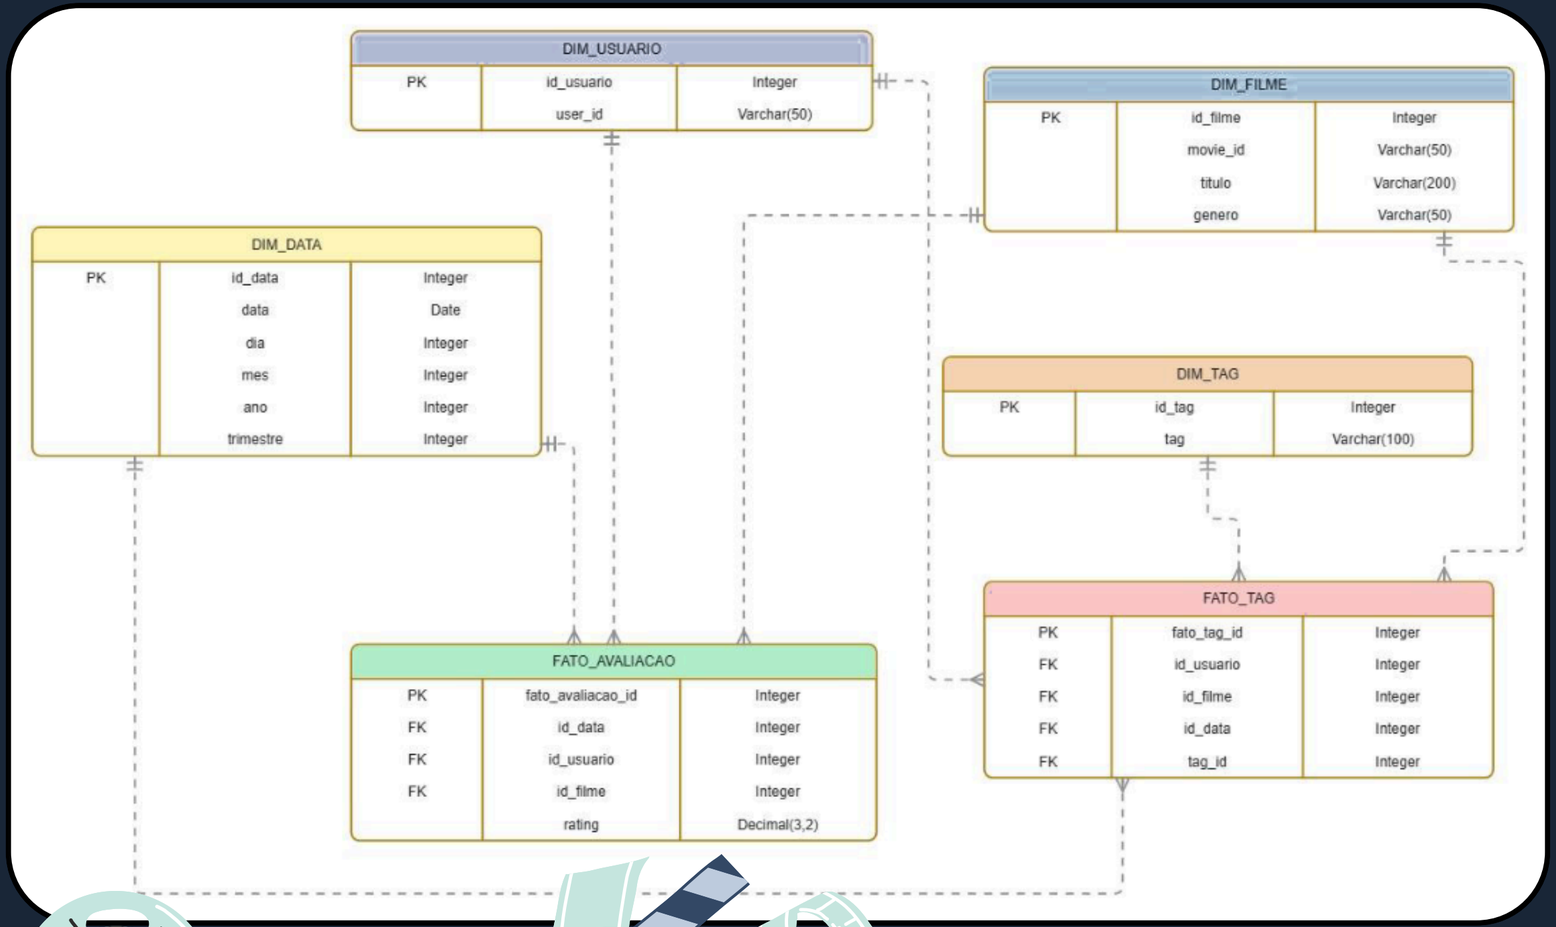

Problems

1. Extract
2. Transform
3. Load

```python
# Função que cria a conexão com o banco
def connect():
    return psycopg2.connect(**DB_CONFIG)

# ------------------------
# EXTRACT
# ------------------------
def extract():...

# ------------------------
# TRANSFORM
# ------------------------
def transform(movies, ratings, tags):...

# ------------------------
# LOAD
# ------------------------
def load(movies, ratings, tags):...

# ------------------------
# MAIN
# ------------------------
def main():
    # Executa todo o pipeline ETL
    movies, ratings, tags = extract()
    movies, ratings, tags = transform(movies, ratings, tags)
    load(movies, ratings, tags)

    print("✨ ETL concluído com sucesso.")
```

Consultas Analíticas

```sql
-- 2. Filmes com maior número de avaliações
SELECT f.titulo, COUNT(*) AS total_avaliacoes
FROM fato_avaliacao a
JOIN dim_filme f ON a.id_filme = f.id_filme
GROUP BY f.titulo
ORDER BY total_avaliacoes DESC
LIMIT 10;
```

```sql
-- 1. Filmes mais bem avaliados
SELECT f.titulo, AVG(a.rating) AS media
FROM fato_avaliacao a
JOIN dim_filme f ON a.id_filme = f.id_filme
GROUP BY f.titulo
HAVING COUNT(*) > 50
ORDER BY media DESC
LIMIT 10;
```

```sql
-- 3. Gêneros mais populares
SELECT f.genero, COUNT(*) AS total
FROM dim_filme f
JOIN fato_avaliacao a ON f.id_filme = a.id_filme
GROUP BY f.genero
ORDER BY total DESC;
```

Top 15 com mais avaliações

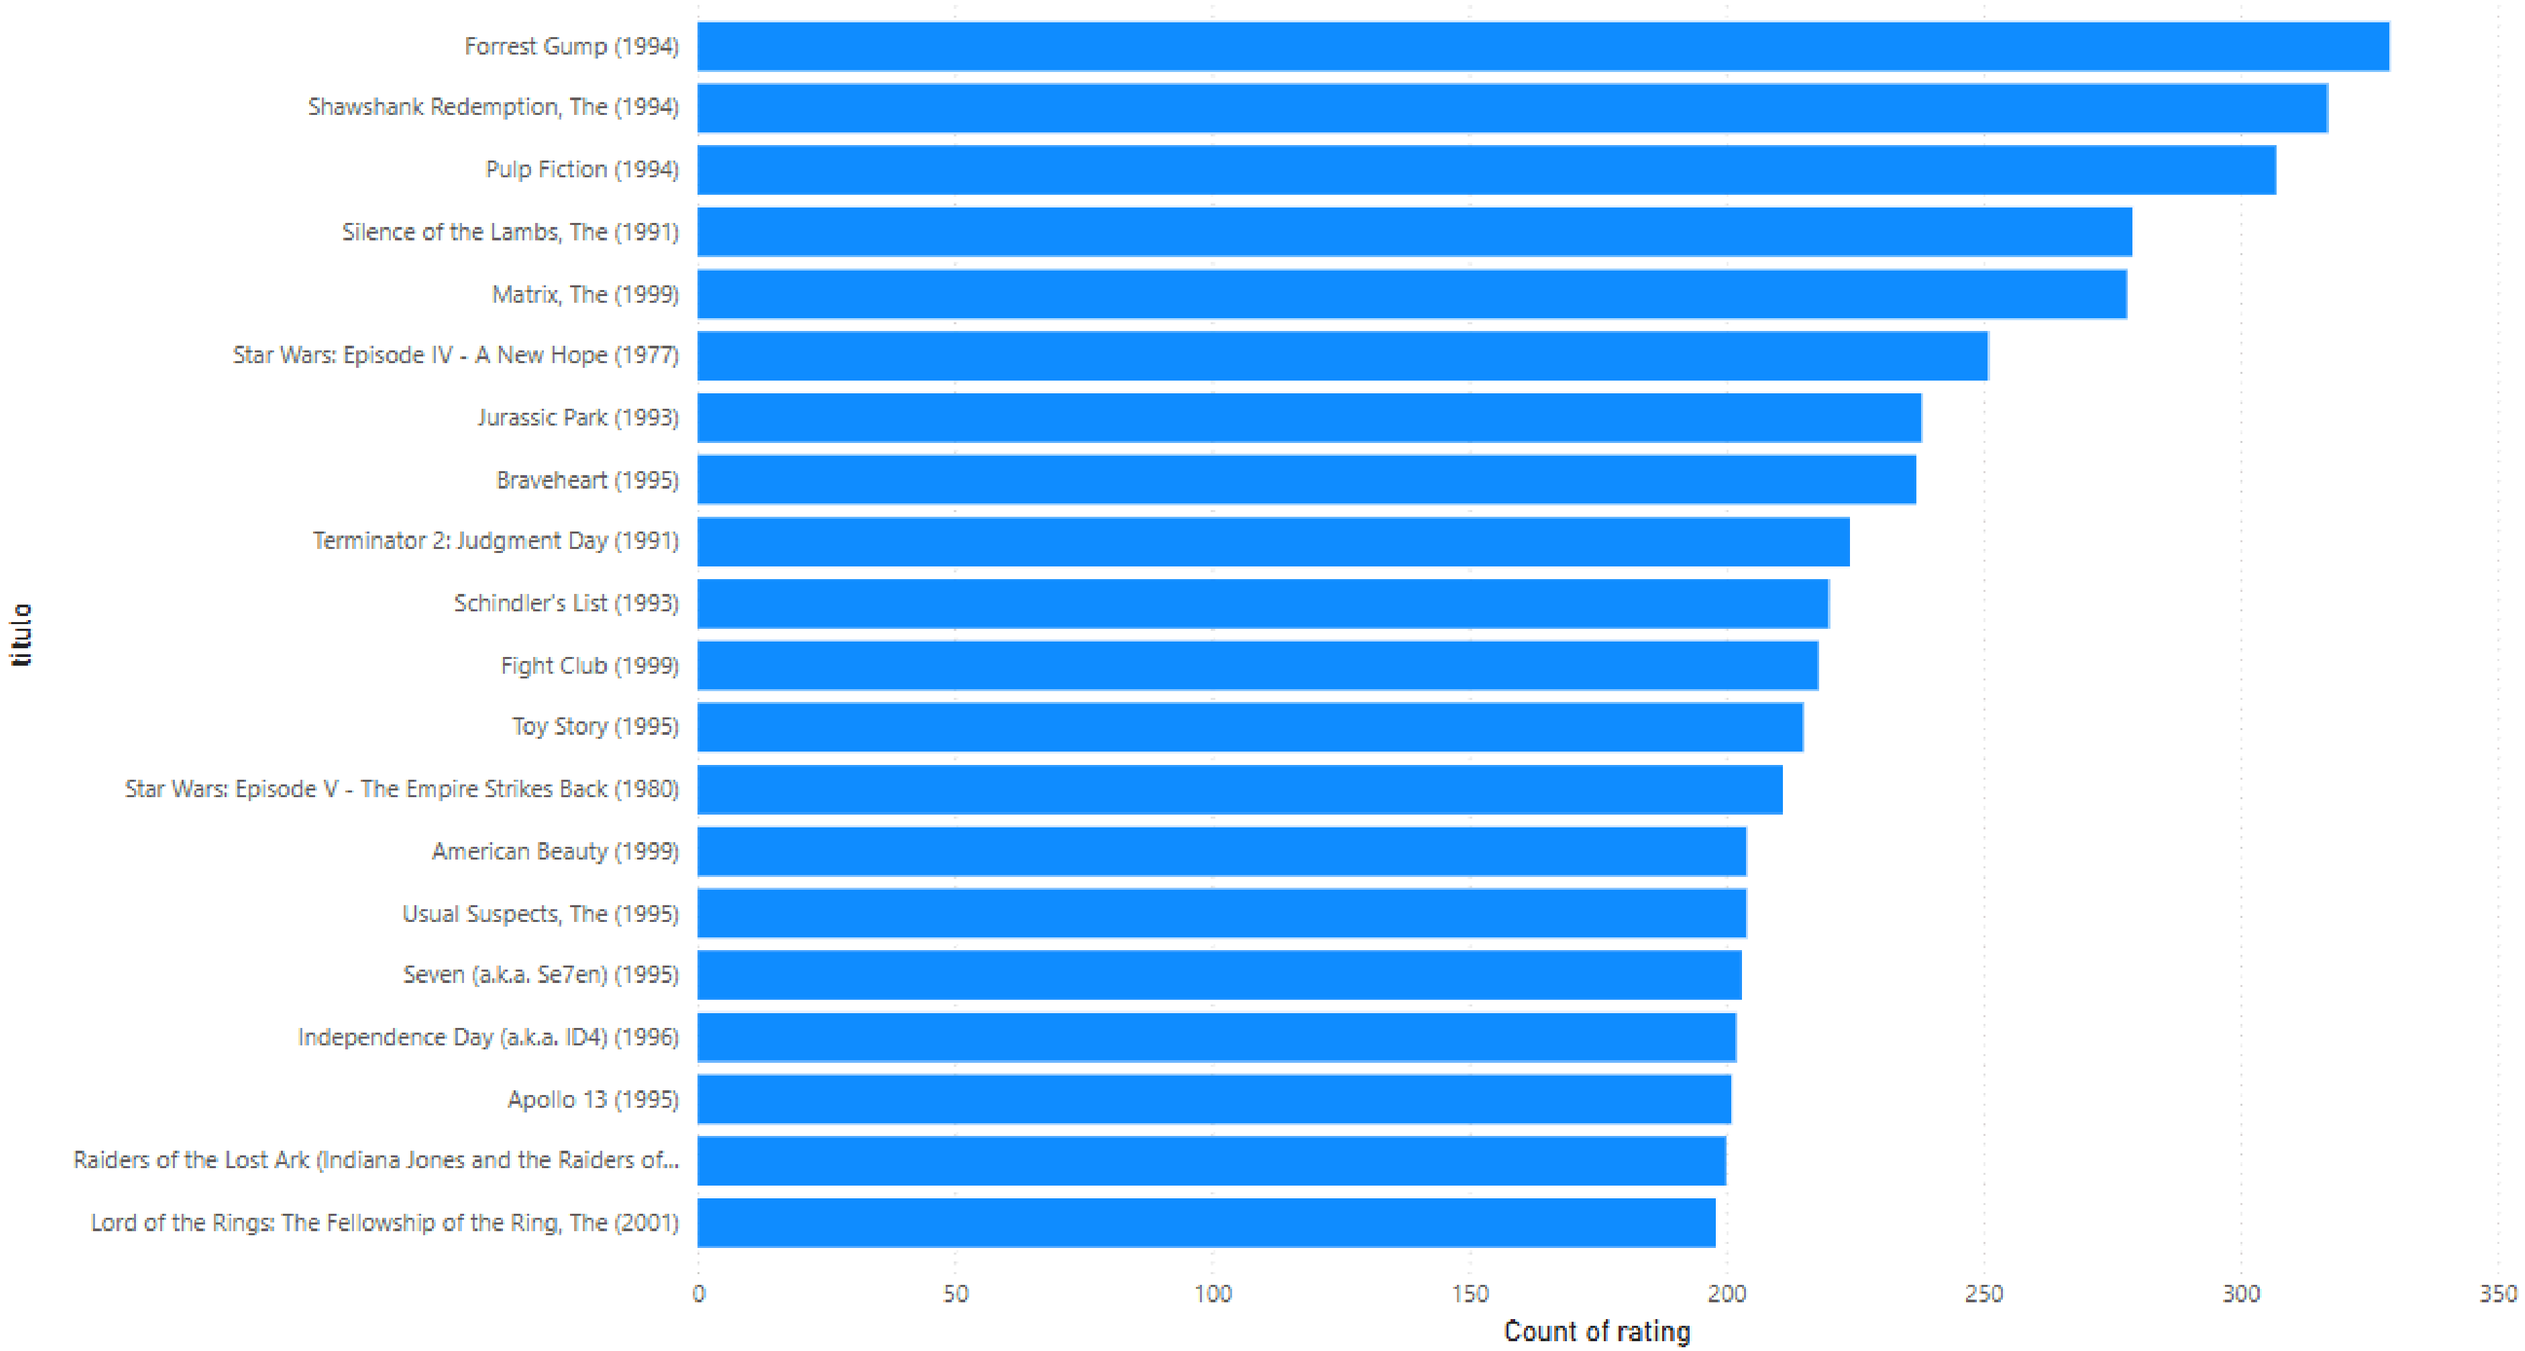

Evolução da quantidade de avaliações

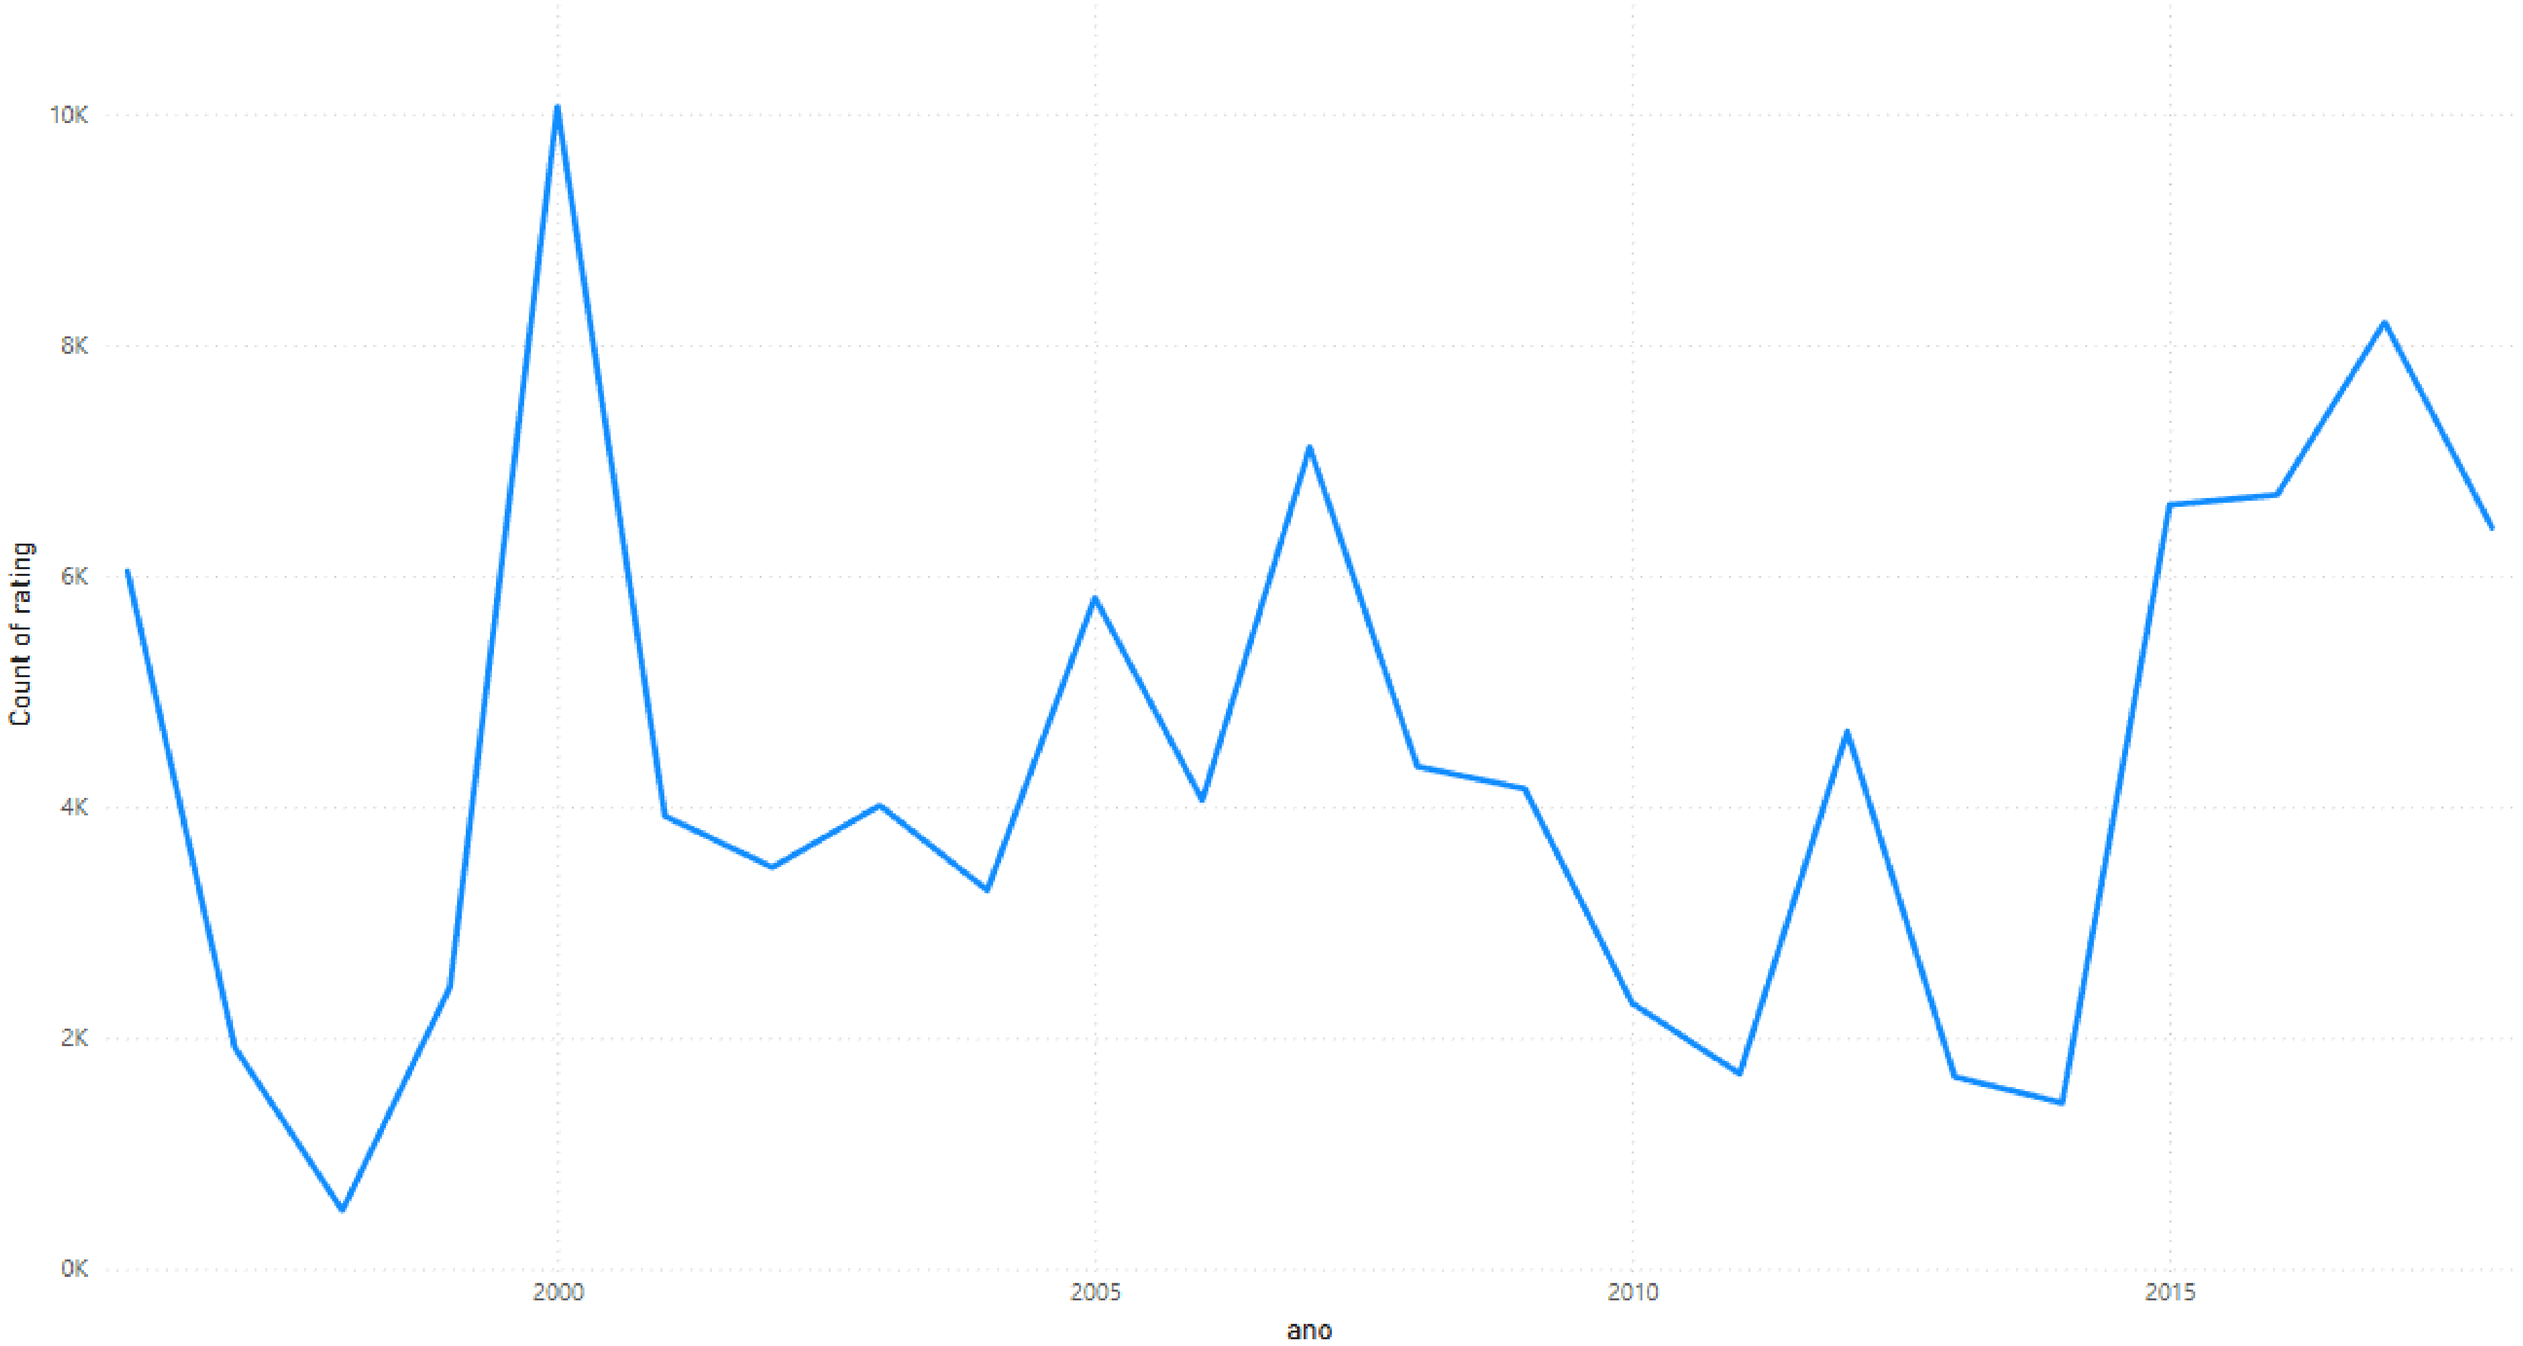

Evolução da média das avaliações
3.9
3.8
3.7
3.6
3.5
3.4
3.3
Average of rating
2000
2005
2010
2015
ano

Gêneros mais populares

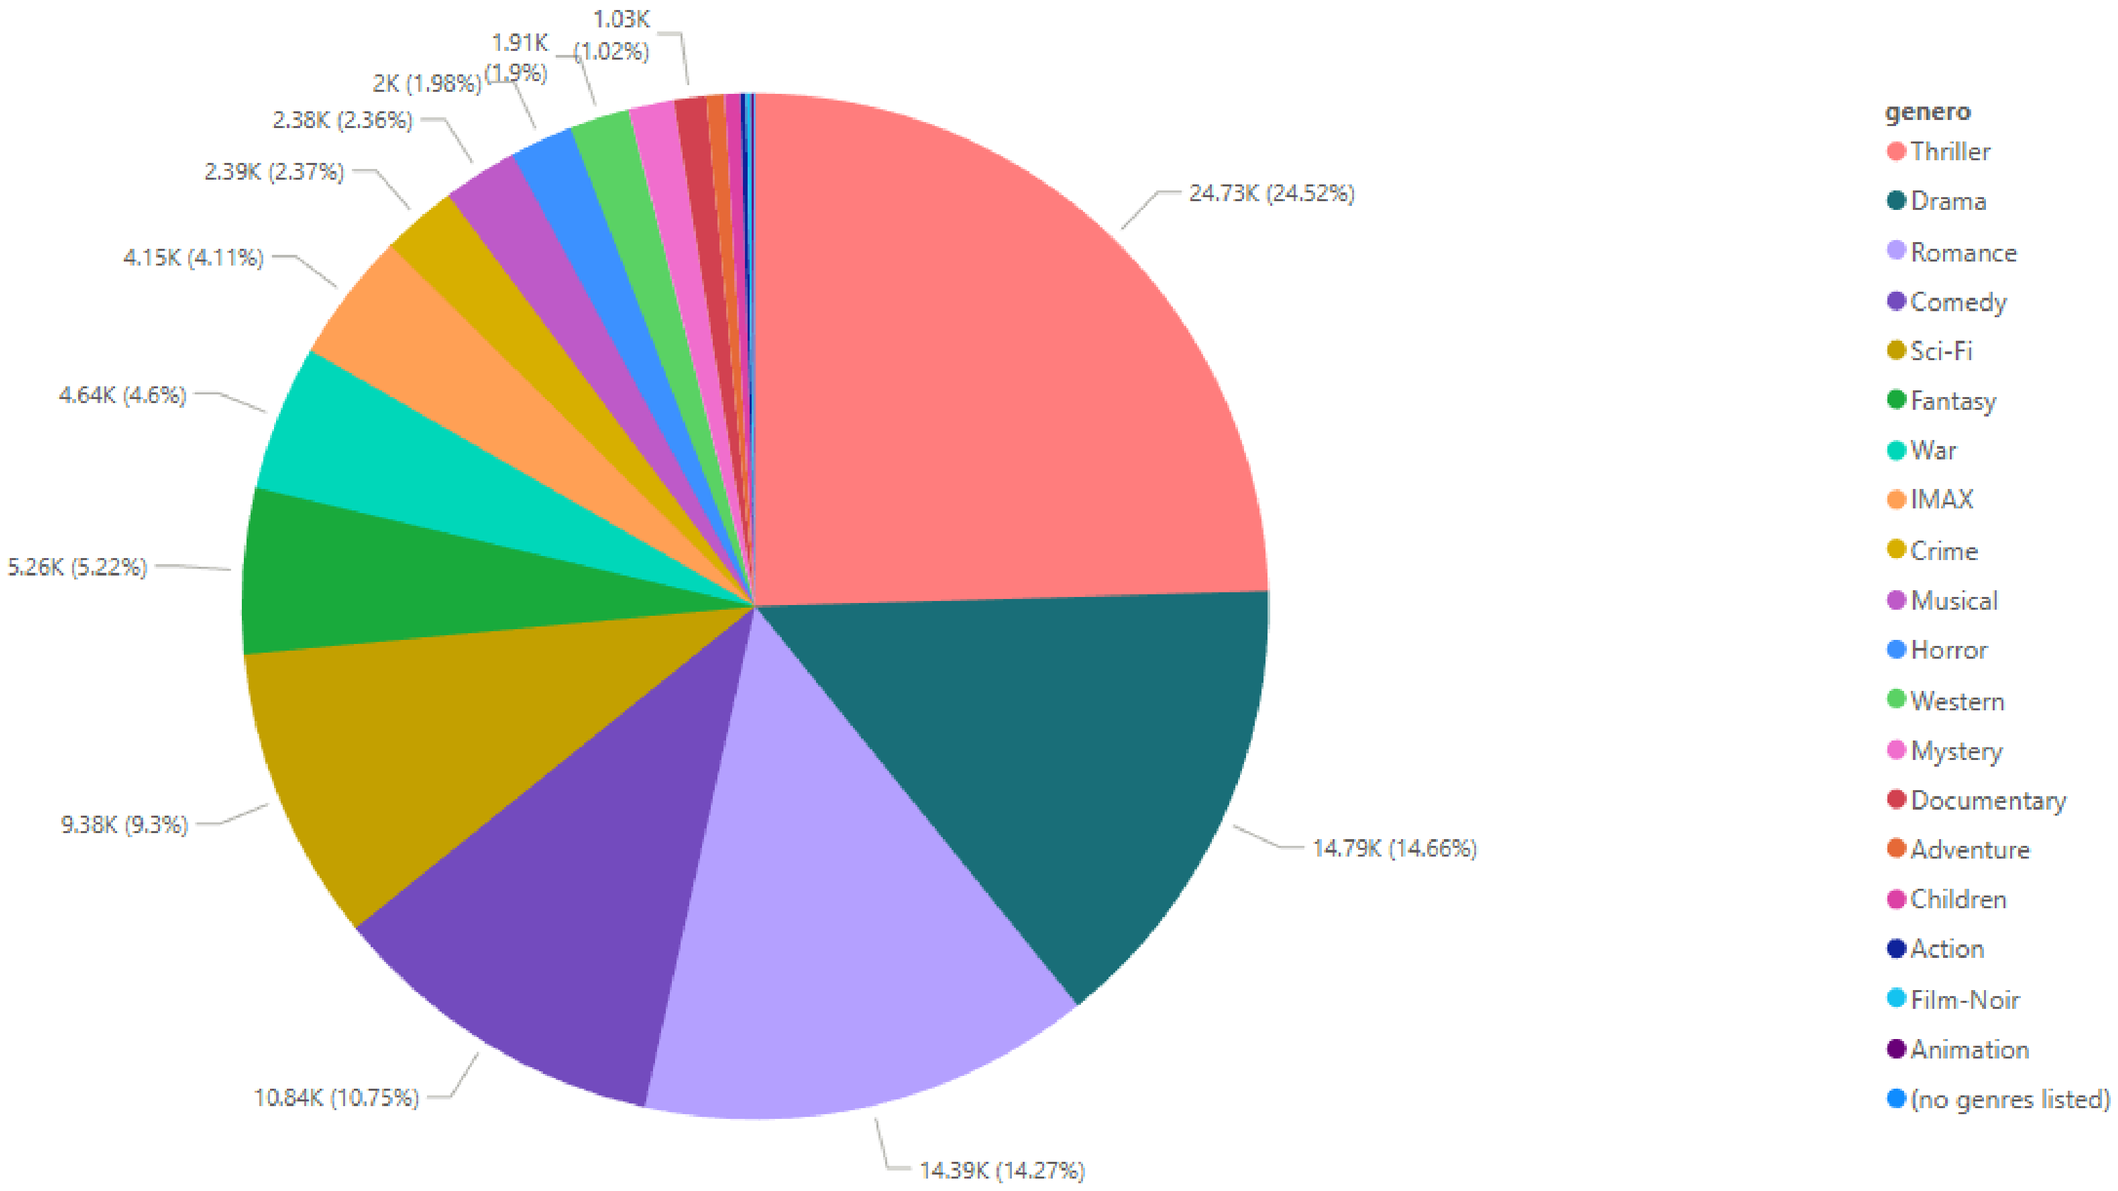

Média por gênero

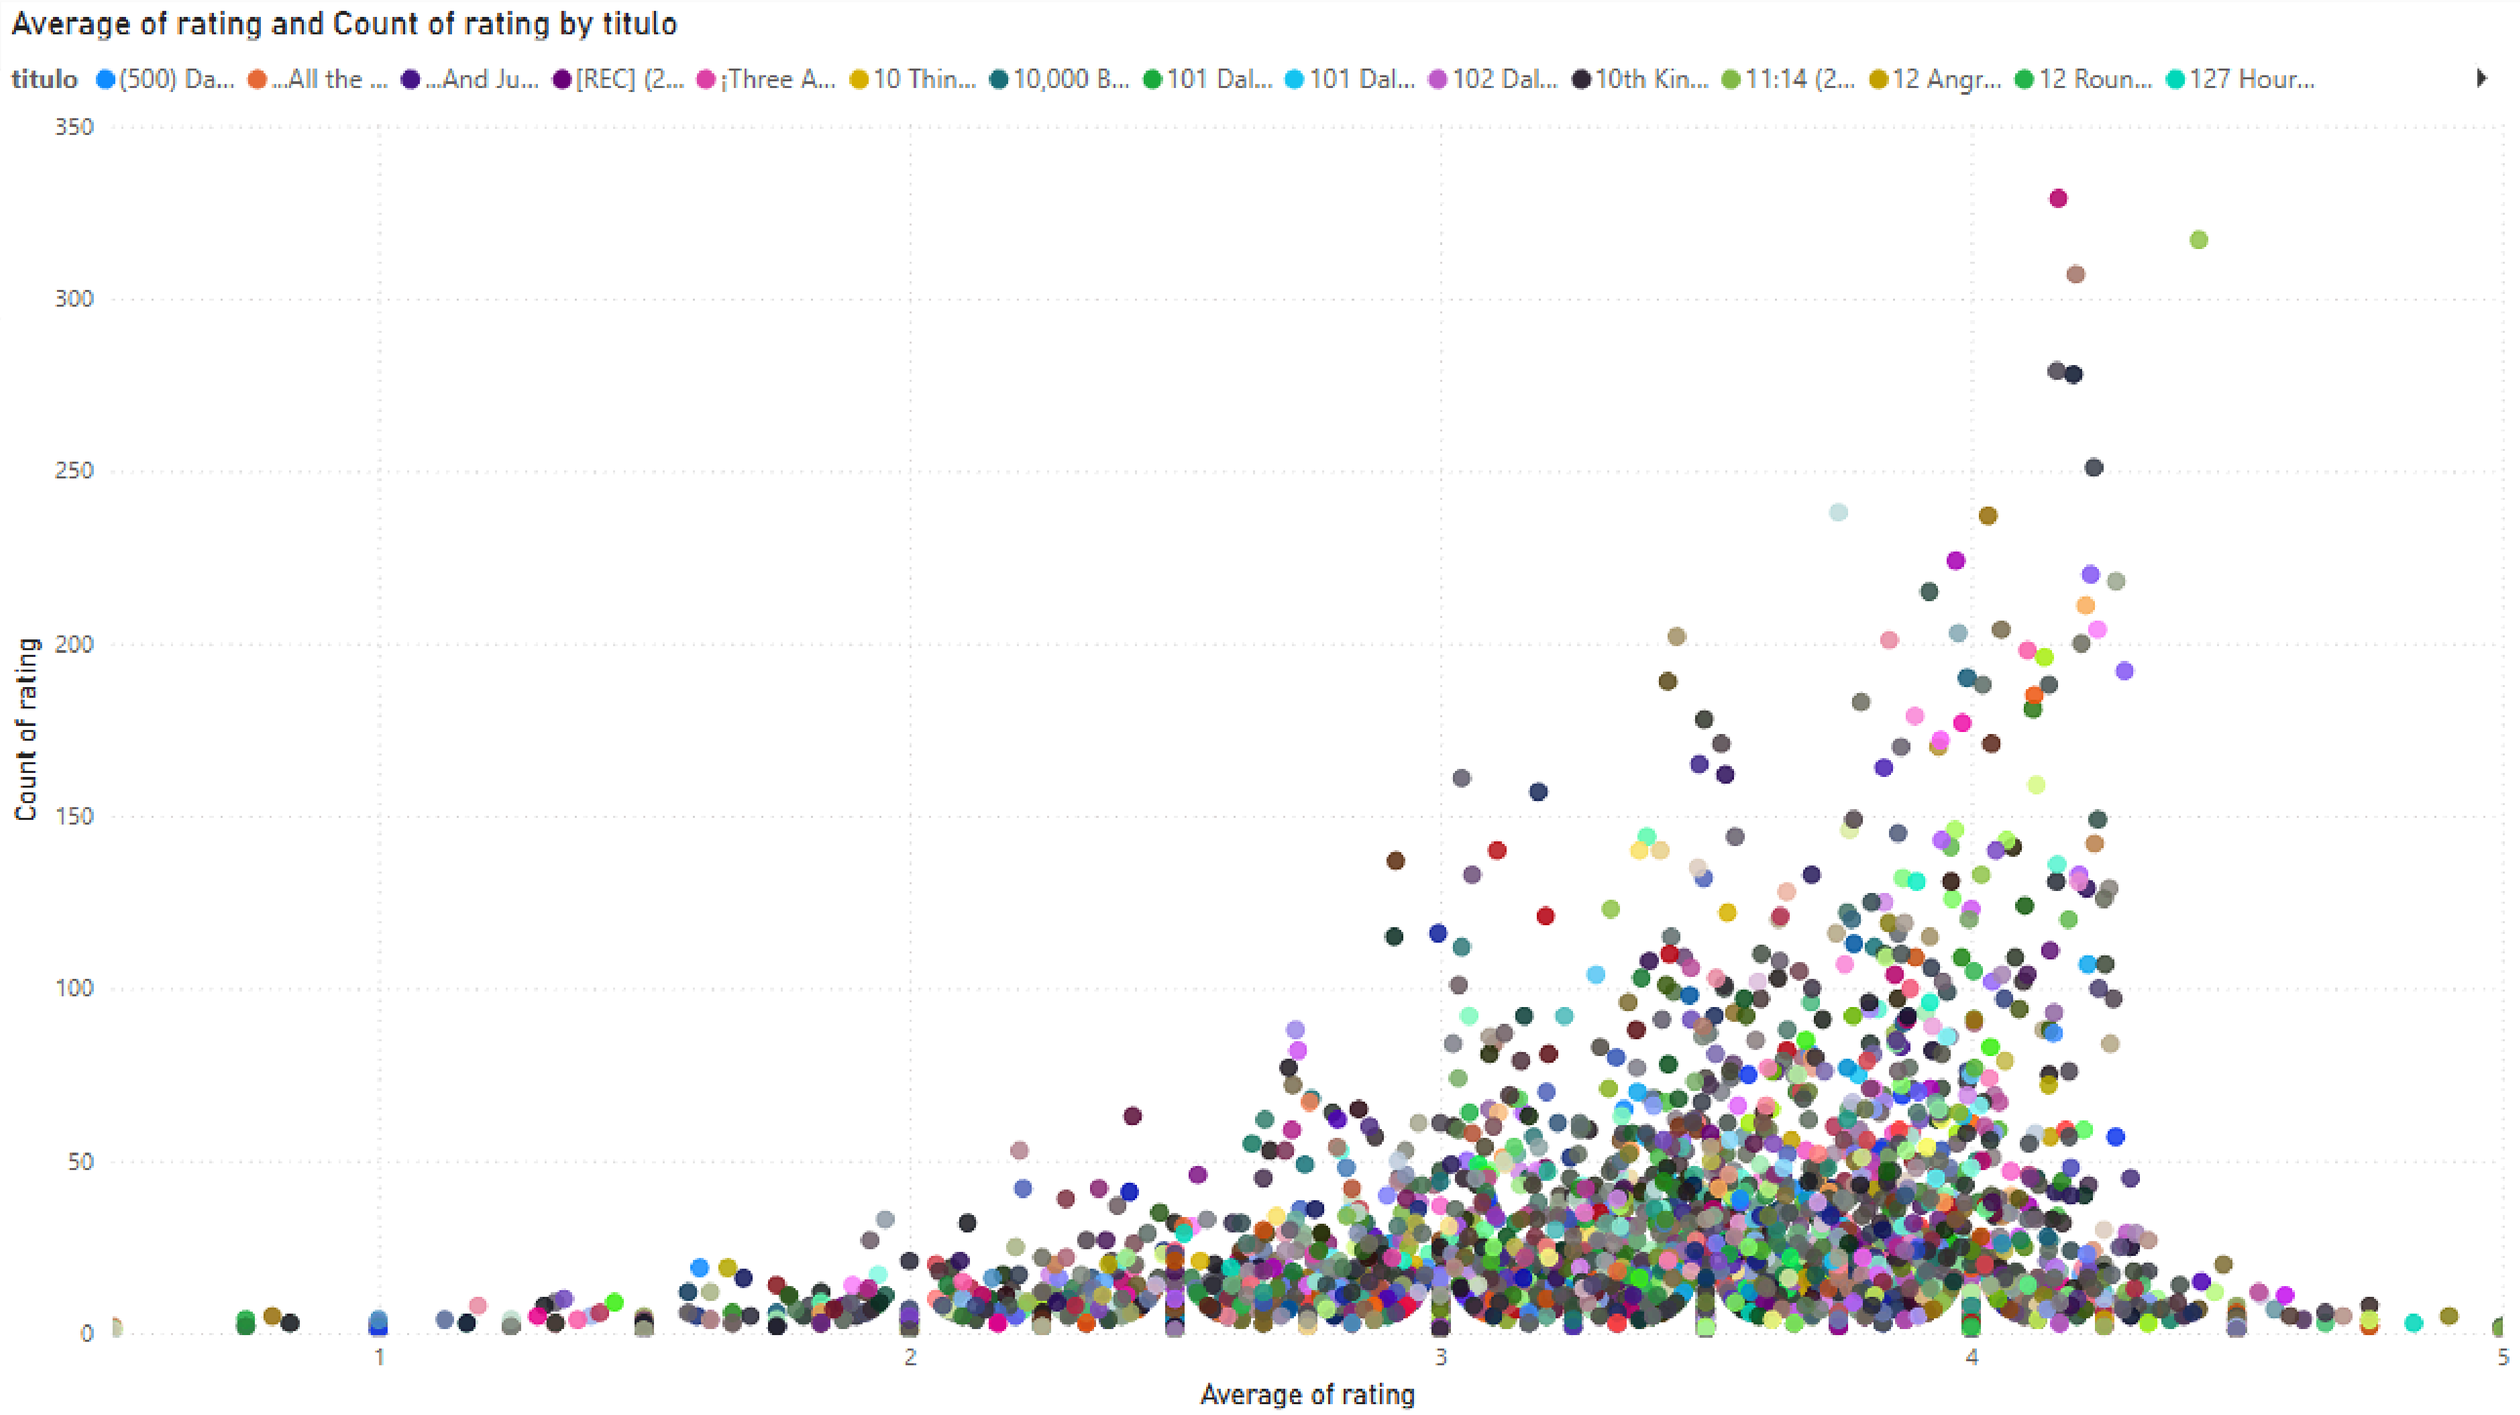
Average of rating and Count of rating by titulo
titulo
(500) Da...
...All the ...
...And Ju...
[REC] (2...
¡Three A...
10 Thin...
10,000 B...
101 Dal...
101 Dal...
102 Dal...
10th Kin...
11:14 (2...
12 Angr...
12 Roun...
127 Hour...
Count of rating
350
300
250
200
150
100
50
0
1
2
3
4
5
Average of rating

Tags mais usadas

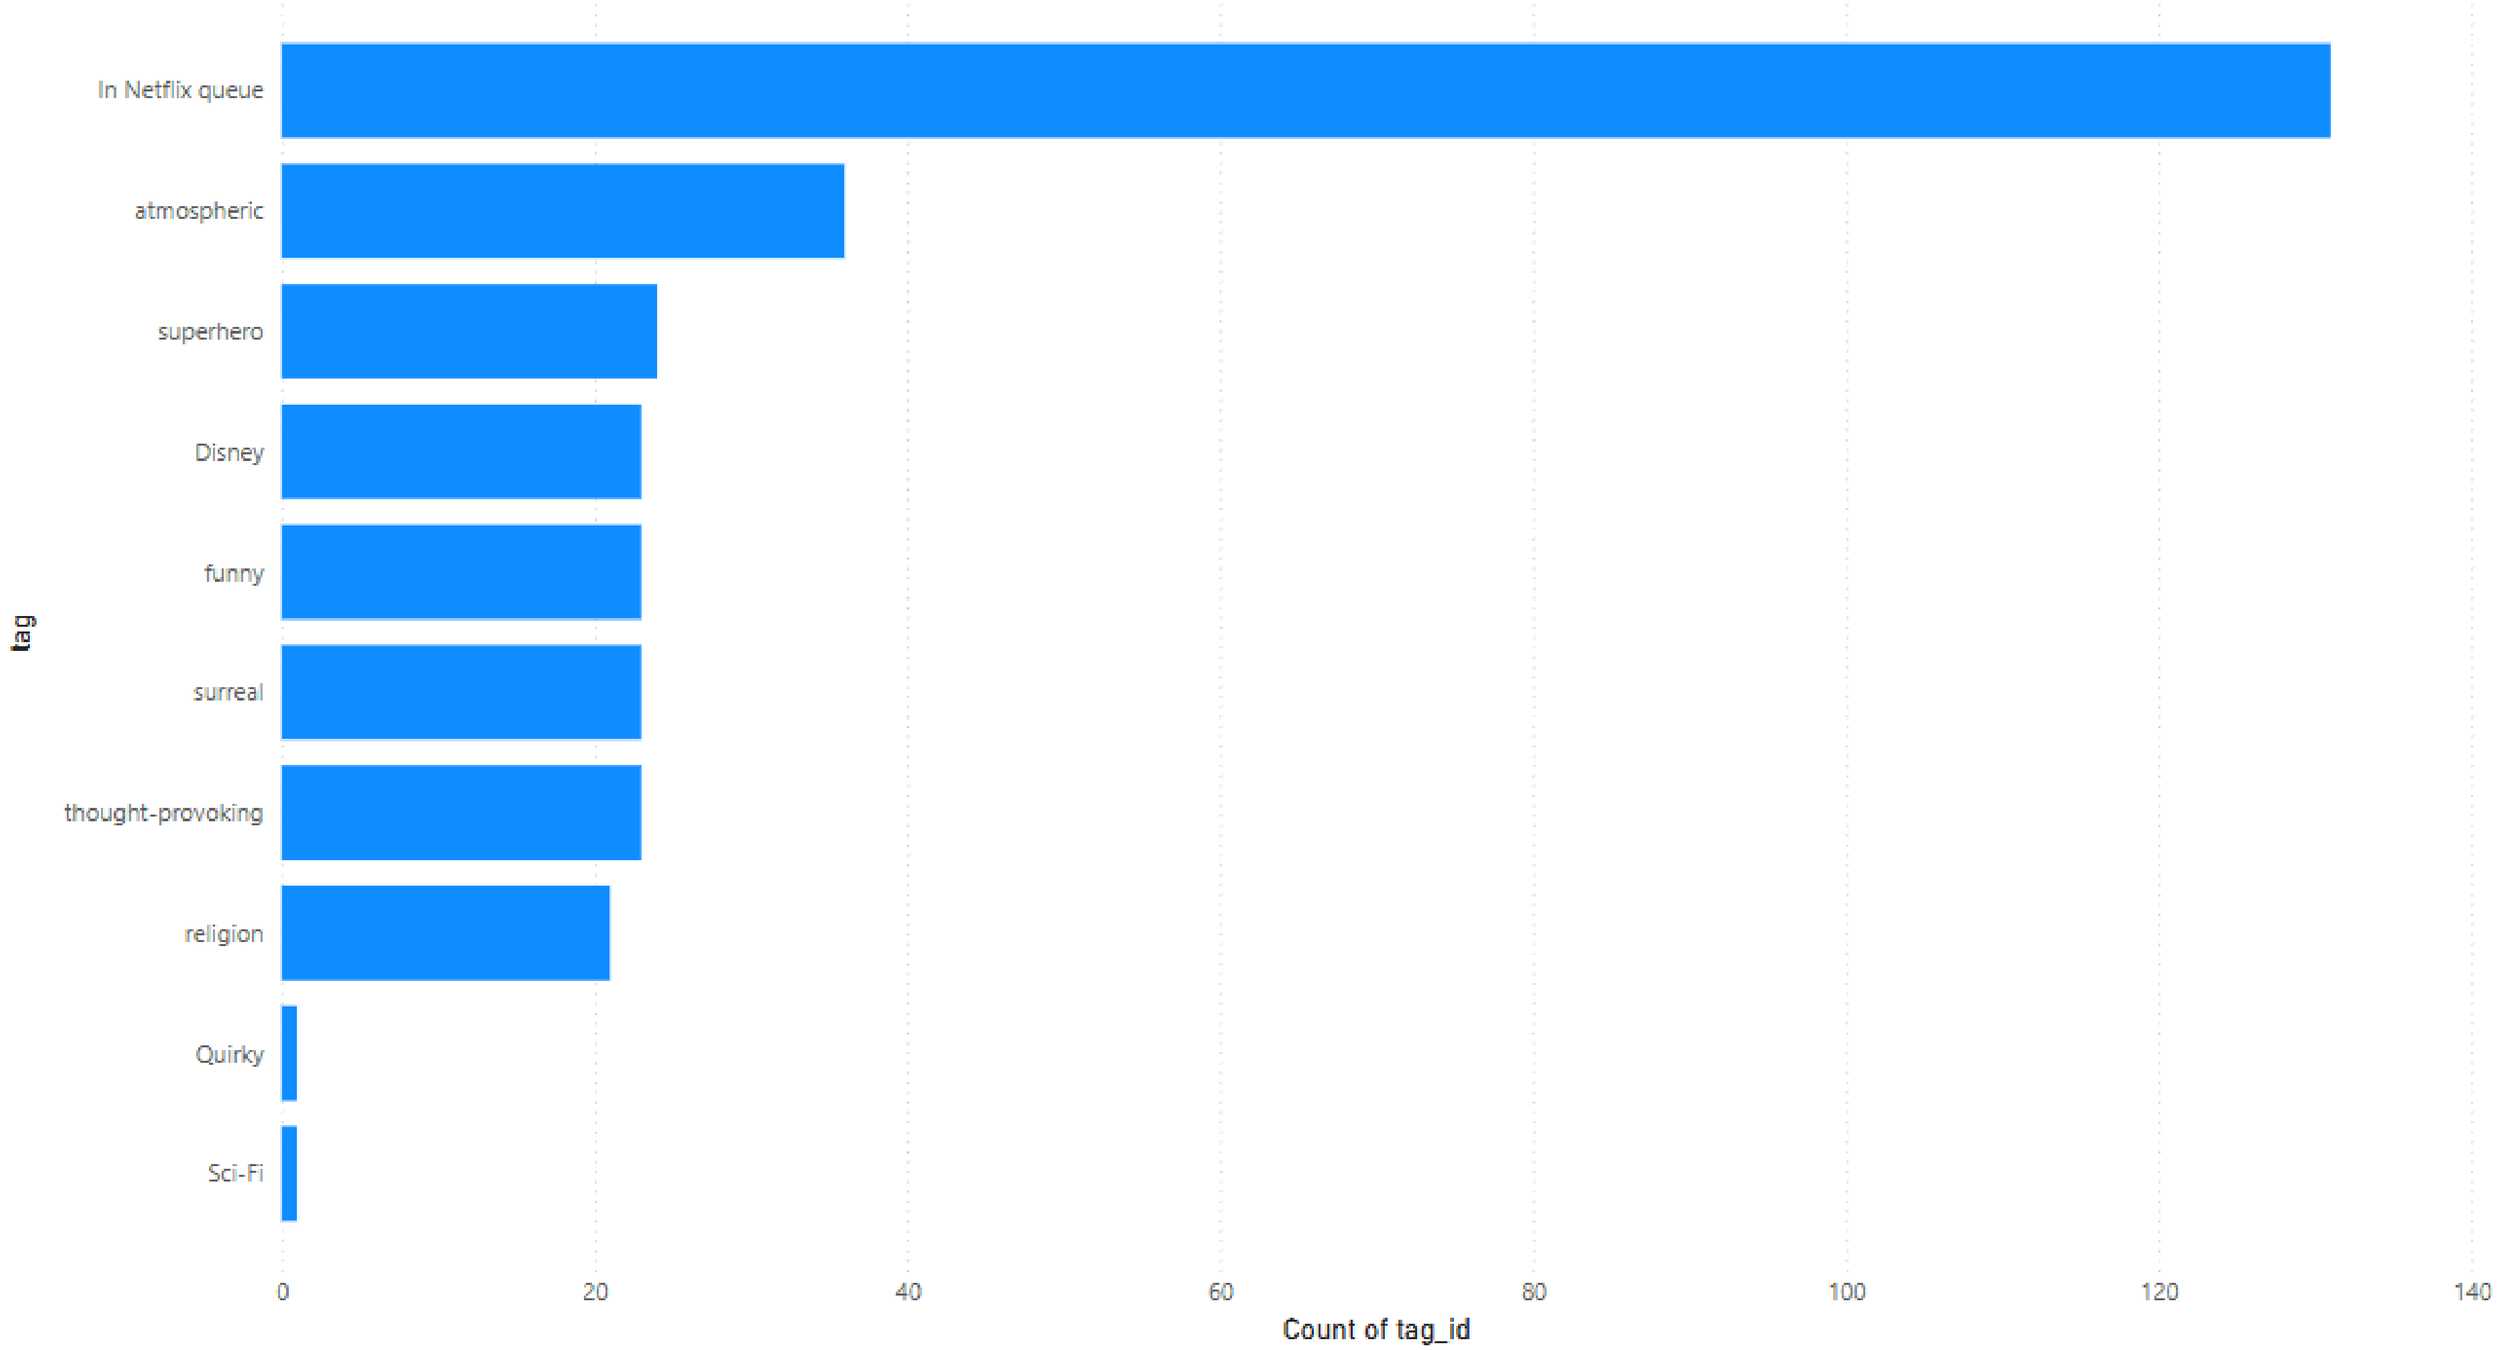

Populariadade X Tags

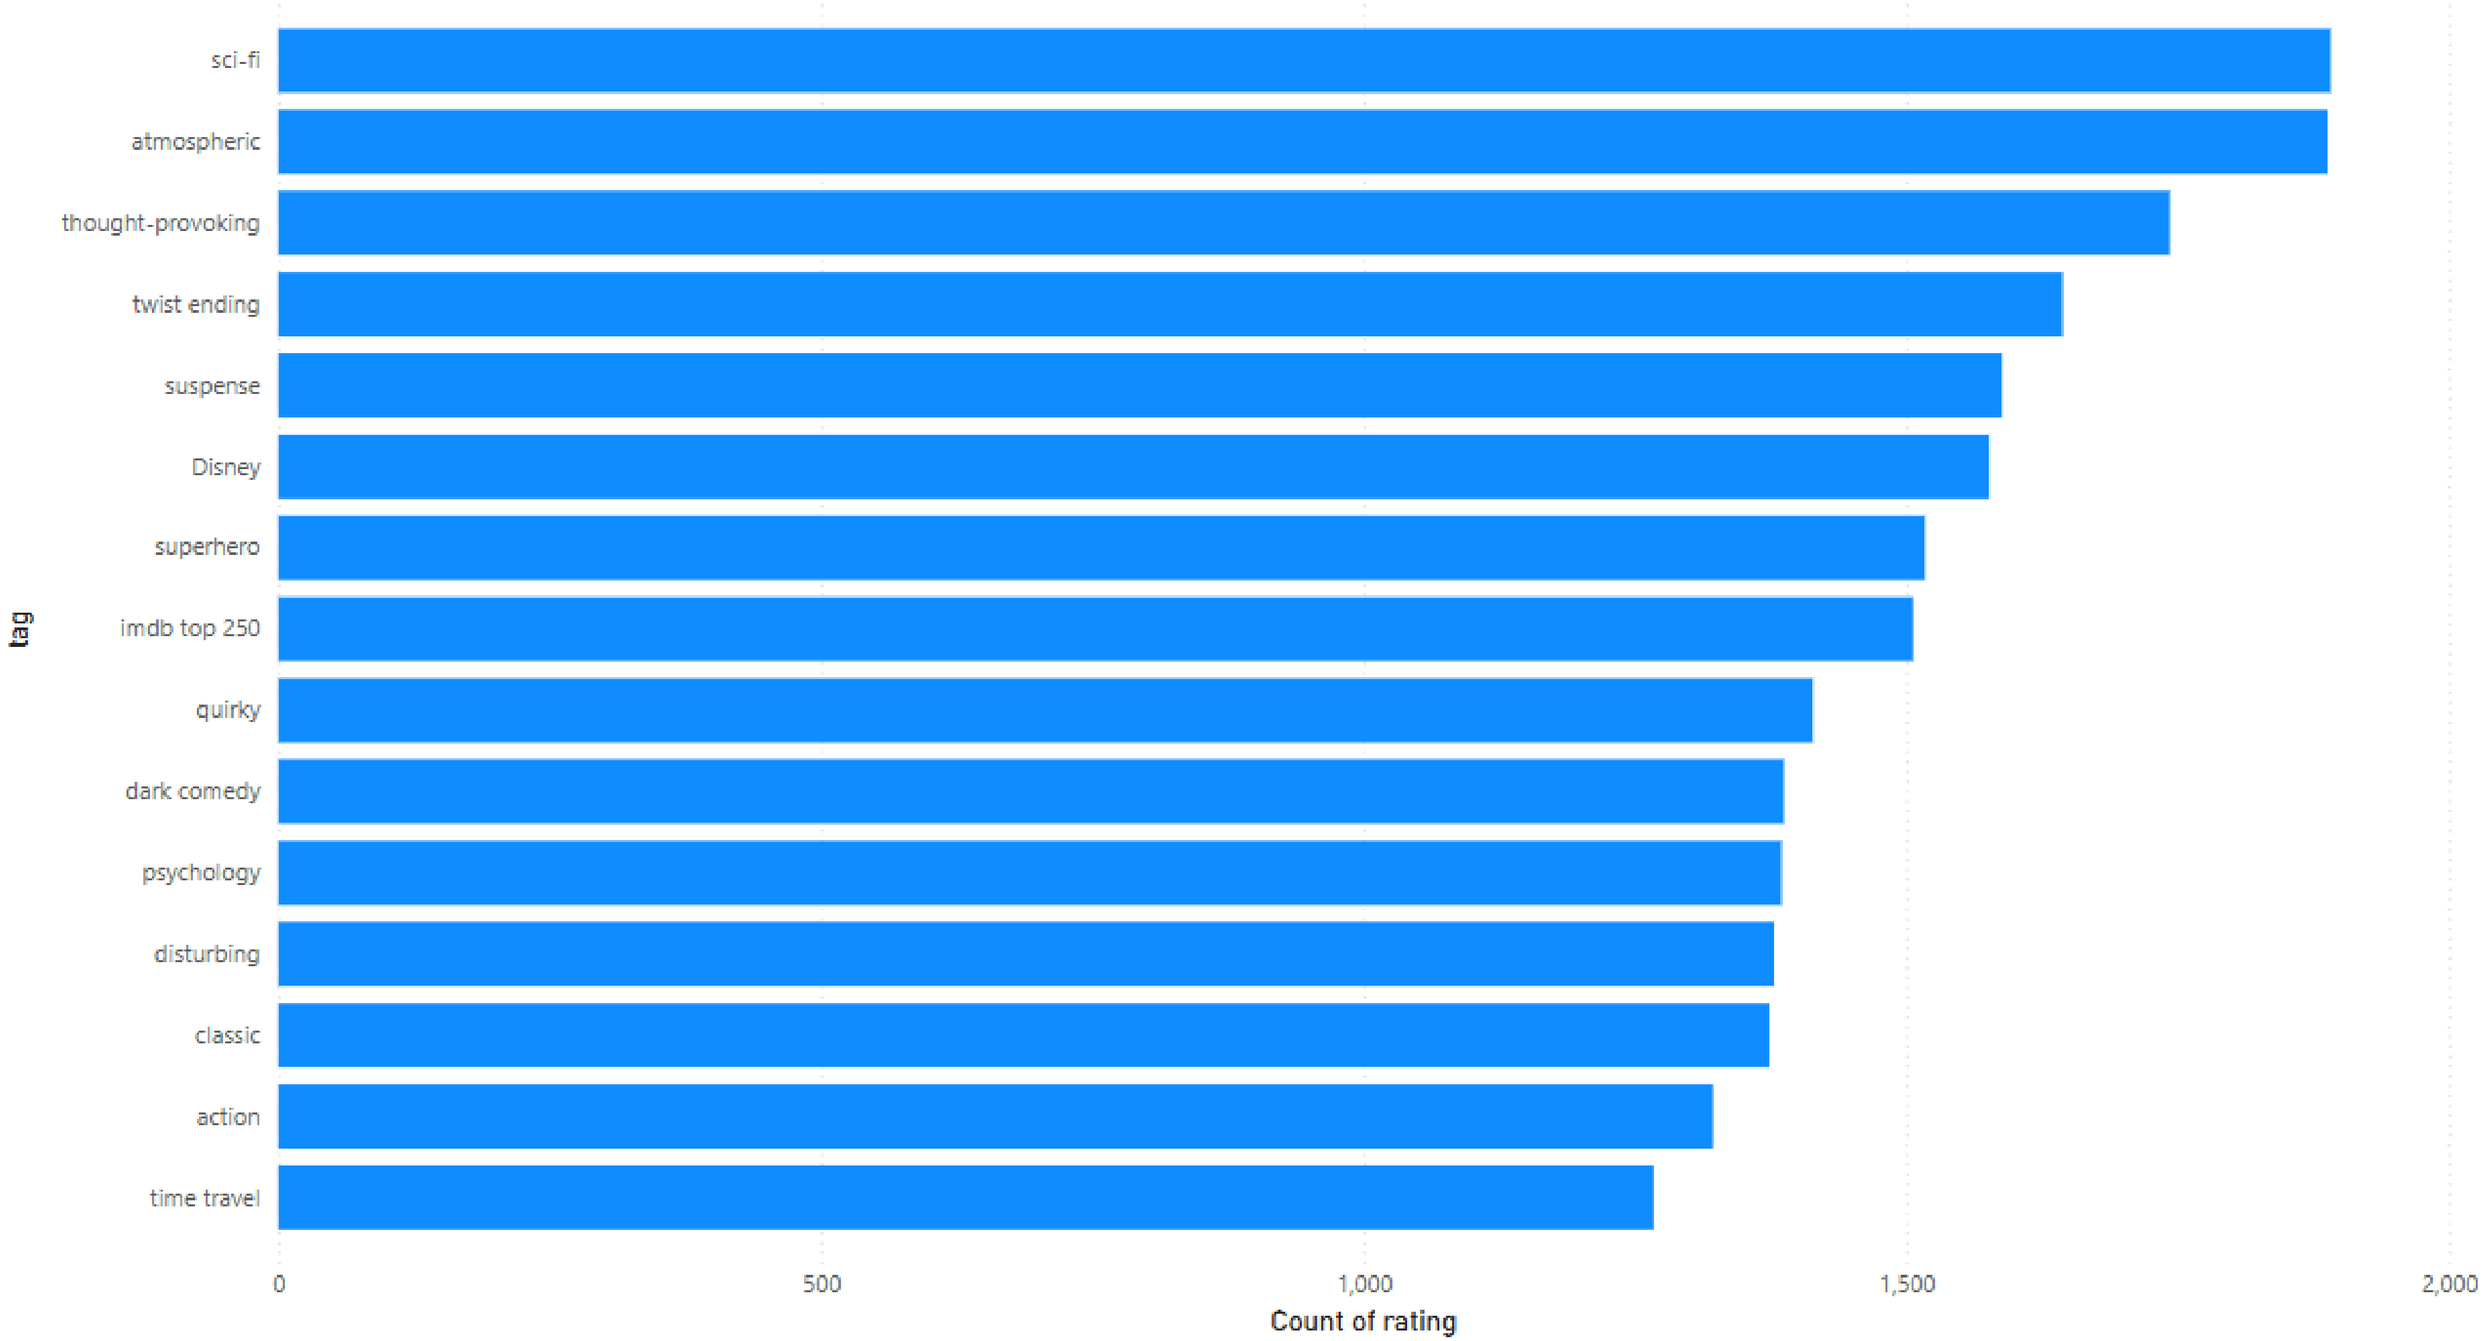

Obrigado Pela Atenção

FINISH